

LeWorldModel

SIGReg 为什么能防塌缩?

World Model

SIGReg

Latent Planning

JEPA

Key Idea

世界模型的基本想法是：**根据当前的状态，采取一个动作之后，能够预测世界下一个时刻的状态**。LeWM 属于 JEPA 路线：不重建像素，而是直接预测下一步 latent。

世界模型

世界模型根据其基本想法，衍生出了许多不同的路线，部分人会把预测视频的下一帧也并入世界模型的范畴。而 JEPA 路线则是先把高维观测压到 latent 空间，再在 latent 里学习 dynamics。这样做的好处是：预测和规划都发生在更紧凑的表示空间里，计算更轻，也更接近控制本身关心的结构。但是与视频相比坏处就是无法直接刻画表征的好坏。

LeWM 是从原始像素出发，端到端学习一个**可预测、可规划、但不塌缩**的 latent world model。

LeWM

训练目标

$$z_t = \text{enc}_\theta(o_t), \quad \hat{z}_{t+1} = \text{pred}_\phi(z_t, a_t).$$

$$\mathcal{L}_{\text{pred}} = \frac{1}{T-1} \sum_{t=1}^{T-1} \|\hat{z}_{t+1} - z_{t+1}\|_2^2, \quad \mathcal{L}_{\text{LeWM}} = \mathcal{L}_{\text{pred}} + \lambda \text{SIGReg}(Z).$$

z_t 就可以当成 t 时刻的“状态”， o_t 是我们观测到的视觉信息（像素）， a_t 是采取的动作。

防止塌缩

假设 encoder 把所有观测都映到同一个向量 c ，也就是

$$z_t \equiv c, \quad \hat{z}_{t+1} \equiv c.$$

那么在欧氏空间下，预测损失立刻变成

$$\|\hat{z}_{t+1} - z_{t+1}\|_2^2 = 0.$$

这说明：在 **next-latent prediction** 这个目标下，点塌缩不是“训练失败”，而是一个**合法的最优解**。一旦如此，所有状态在 latent 空间中都不可区分。当前状态、目标状态、预测终点都会落在同一个点上，于是任何动作序列看起来都一样好，规划也就失去了意义。

SIGReg

记 latent 样本矩阵为

$$Z \in \mathbb{R}^{n \times d}.$$

SIGReg 的目标是更强的一件事：把 latent 的经验分布推向各向同性高斯 $\mathcal{N}(0, I_d)$ 。

SIGReg

采样随机单位方向

$$u^{(m)} \sim \text{Unif}(\mathbb{S}^{d-1}), \quad m = 1, \dots, M,$$

做一维投影

$$h^{(m)} = Zu^{(m)} \in \mathbb{R}^n,$$

然后平均一维正态性统计量：

$$\text{SIGReg}(Z) = \frac{1}{M} \sum_{m=1}^M T(h^{(m)}).$$

其中 T 是 Epps–Pulley 统计量，用来衡量投影样本与标准正态 $\mathcal{N}(0, 1)$ 的距离。

理论依据是：一个高维分布，可以由它在所有一维方向上的投影分布刻画。所以，高维 anti-collapse 问题可以转化成很多个一维问题：随机看几个方向，检查投影后是否是近似标准高斯。这样一来，常值解、低秩表示、强相关表示都会被排除。

Latent Planning

训练结束后，固定 encoder 和 predictor。给定当前观测 o_1 与目标观测 o_g ，先编码为

$$\hat{z}_1 = \text{enc}_\theta(o_1), \quad z_g = \text{enc}_\theta(o_g).$$

然后在 latent 空间里滚动预测：

$$\hat{z}_{t+1} = \text{pred}_\phi(\hat{z}_t, a_t), \quad t = 1, \dots, H - 1.$$

规划目标是

有限时域目标

$$a_{1:H}^* = \arg \min_{a_{1:H}} \|\hat{z}_H - z_g\|_2^2.$$

planner 不修改 latent。它真正优化的是一串动作，使 world model 预测出来的终点 latent，尽可能靠近目标观测的 latent 编码。

实现上使用的是 CEM 配合 MPC：在动作序列空间里反复采样、筛选、更新，再持续重规划，以减轻长时滚动造成的模型误差积累。

Takeaway

LeWM 先用预测损失学出动作条件下的 latent dynamics，再用 SIGReg 给 latent 空间施加非塌缩的分布几何；而 latent planning 则是在这套冻结的 dynamics 上，搜索一串动作，让预测终点尽量到达目标 latent。

参考文献

1. Lucas Maes, Quentin Le Lidec, Damien Scieur, Yann LeCun, Randall Balestriero. *LeWorld-Model: Stable End-to-End Joint-Embedding Predictive Architecture from Pixels*. arXiv preprint, 2026.
2. David Ha, Jürgen Schmidhuber. *World Models*. arXiv preprint arXiv:1803.10122, 2018.
3. Yann LeCun. *A Path Towards Autonomous Machine Intelligence*. Open Review, 2022.
4. Randall Balestriero, Yann LeCun. *LeJEPa: Provable and Scalable Self-Supervised Learning without the Heuristics*. arXiv preprint, 2025.

5. Thomas W. Epps, Lawrence B. Pulley. *A Test for Normality Based on the Empirical Characteristic Function*. Biometrika, 70(3):723–726, 1983.
6. Harald Cramér, Herman Wold. *Some Theorems on Distribution Functions*. Journal of the London Mathematical Society, 1(4):290–294, 1936.
7. Reuven Y. Rubinstein, Dirk P. Kroese. *The Cross-Entropy Method: A Unified Approach to Combinatorial Optimization, Monte-Carlo Simulation and Machine Learning*. Springer, 2004.